



38 лет (родился 11 января 1988), высшее образование, не состоит в браке, детей нет
Калининград, готов к переезду, удаленная работа
Гражданство: Россия

Профессиональные навыки

Python

SQL

pandas

Matplotlib

Machine Learning

Scikit-learn

PyTorch

Математическая статистика

Catboost

MS Excel

Keras

xgboost

Data Science

Seaborn

NLP

SciPy

Deep Learning

A/B тесты

PHP

JavaScript

Data Scientist

Полная занятость

По договорённости

Опыт работы 4 года и 6 месяцев

Апрель 2022 –
работает сейчас
4 года и 6 месяцев

Data Scientist

Фриланс, Москва
<http://kaggle.com>
Competitions

Обязанности и достижения:

Анализ данных и применение методов машинного обучения для предсказания результатов
Решения проектов: <https://github.com/basketbob>

ПРОЕКТ:

Тех. обслуживание машин каршеринга

ЗАДАЧА:

На основе табличных данных, построить модель предсказания поломки машины.

Данные:

car_train.csv - главное описание машин с информацией о поломках для обучения / прогноза
rides_info.csv - информация про поездки
driver_info.csv - информация про водителей
fix_info.csv - информация про ремонт машин

РЕШЕНИЕ:

В данном проекте будем использовать классическое обучение с учителем, тип задачи классификация (9 видов поломки). Алгоритм решения будем использовать CatBoostClassifier.
Загружаем данные, анализируем, подготавливаем для модели и в сыром виде обучаем, для точки старта.
Далее чистим и генерируем признаки. Тюним гиперпараметры модели с помощью библиотеки optuna.
Обучаем модель, получаем лучшую метрику. Делаем предсказания и сохраняем в файл.

ПРОЕКТ:

Дипломная работа "Темп бега на дистанции 42.2 км"

ЗАДАЧА:

На основе данных о тренировках, предсказать соревновательный темп бега на дистанцию 42.2 км.

РЕШЕНИЕ:

1. Сбор (парсинг) данных о тренировках спортсменов из социальной сети Strava.
 2. Анализ, чистка и генерация признаков.
 3. У нас тип задачи - обучение с учителем, регрессия, подбираем алгоритмы на основе этого.
 4. Отбираем спортсменов, которые уже пробежали марафон и на их основе обучаем 5 разных моделей: градиентный бустинг, линейная регрессия, нейросеть, деревья решений и случайный лес.
 5. Выбираем лучшую метрику и сохраняем соответствующую модель.
-

ПРОЕКТ:

Использование LLM для ответа на сложные научные вопросы

ЗАДАЧА:

Имеется датасет из вопросов, 5 вариантов ответа и правильный ответ. Необходимо обучить модель, которая будет предсказывать правильный ответ. Каждый вопрос состоит из подсказки (вопроса), 5 вариантов ответов, обозначенных A, B, C, D и E, и правильного ответа, обозначенного как answer (в нем содержится метка наиболее правильного ответа).

РЕШЕНИЕ:

1. Подготовка данных: Из датафрейма с вопросами и вариантами ответов формируются запросы. К этим запросам прикрепляются соответствующие фрагменты из статей Википедии, которые могут помочь модели в принятии решения.
2. Токенизация: Запросы преобразуются в числовую форму (токены) с помощью специального инструмента — токенизатора.
3. Запуск модели: На основе токенизированных запросов модель прогнозирует, является ли предложенный ответ правильным или нет.
4. Обработка результатов: После получения результатов от модели для каждого вопроса выбираются три наиболее вероятных ответа.
5. Сохранение результатов: Финальные предсказания сохраняются в файл CSV для последующей отправки (например, на платформу Kaggle).

Решается задача анализа вопросов и ответов с использованием глубокого обучения и контекста из Википедии. Модель оценивает, верен ли предложенный ответ на вопрос, исходя из предоставленной информации.

ПРОЕКТ:

CommonLit - Оценка сочинений студентов

ЗАДАЧА:

Оценить качество сочинений, написанных учащимися 3-12 классов. Необходимо создать модель, оценивающую, насколько хорошо учащийся представляет основную идею и детали исходного текста, а также ясность, точность и беглость языка, используемого в сочинении.

РЕШЕНИЕ:

1. Загрузка данных
 2. Предобработка данных (Preprocess):
Извлечение признаков: Из текста извлекаются различные признаки, такие как длина текста, соотношение длины, перекрытие слов и совпадение N-грамм. Эти признаки могут помочь модели определить, насколько хорошо учащийся понимает исходный текст.
Проверка грамматики: Используется инструмент ruyspellchecker для проверки орфографии в тексте. Это может помочь оценить ясность, точность и беглость языка сочинения.
 3. После предварительной обработки данных и извлечения признаков, обучение двух типов моделей: DeBERTa v3 и LightGBM. Обе модели обучаются с использованием кросс-валидации.
 4. Предсказание оценки качества сочинений, запись в файл результатов.
 5. Подсчет метрики.
-

ПРОЕКТ:

Рекомендации товаров для маркетплейса

ЗАДАЧА:

Необходимо создать рекомендательную систему для персональных рекомендаций товаров пользователям сервиса на основании данных за 12 недель работы маркетплейса. Порекомендовать 20 товаров для покупки

пользователем в следующие 7 дней на двух временных промежутках.

РЕШЕНИЕ:

1. Загрузка данных.
2. Анализ и генерация признаков.
3. Первичное обучение модели
4. Удаление лишних признаков
5. Финальное обучение модели
6. Предсказание результатов и сохранение в файл.

Для обучения и применения модели выбран алгоритм классификации CatBoostClassifier

Образование

Высшее образование,
дистанционная форма
2023

Нетология

Специальность: Data Scientist: с нуля до middle

Высшее образование,
дневная/очная форма
2012

Калининградский государственный технический университет

Факультет: Автоматизации производства и управления

Специальность: Прикладная информатика (в экономике)

Обо мне

Дополнительные сведения:

Меня зовут Владимир, и я искренне заинтересован в вакансии Data Scientist. В течение 14 лет я работал веб-разработчиком, активно используя технологии, такие как PHP, JavaScript, SQL. Этот опыт дал мне глубокое понимание алгоритмов, структур данных и программирования, что, как я считаю, будет ценным для роли Data Scientist.

Сменил квалификацию и углубленно изучил область Data Science, включая Python, основные статистические показатели, анализ данных и математику, защитил красный диплом. Активно принимаю участие в соревнованиях на Kaggle и российских площадках.

Способен к многозадачности, быстро реагировать на изменение приоритетов, соблюдаю дедлайны.

Продуктивный, уверенный, нацелен на конечный результат.

Коммуникабельный. Способен доступно излагать техническую информацию нетехническим языком.

Способен успешно работать как в команде, так и самостоятельно.

Слежу за развитием индустрии и новыми трендами, технологиями, стандартами. Открыт к изучению и использованию новых языков и инструментов.

Обладаю навыками всестороннего анализа. Способен решать проблемы комплексно.

Демонстрирую профессиональный и открытый подход к работе.

Способен к быстрой обучаемости.

Имею успешный опыт выполнения работы удаленно.

Владею английским на уровне чтения технической документации.

Я практик, не теоретик, поэтому предпочитаю тестовое задание, вместо теоретического опроса.

Иностранные языки

Английский язык — базовый

Водительские права

A — мотоциклы

В — легковые авто

